

Performance Evaluation of Combined Vectorization Methods and Machine Learning Algorithms on Sentiment Analysis of Chinese Electric Cars

Evaluasi Kinerja Kombinasi Metode Vektorisasi dan Algoritma Machine Learning pada Analisis Sentimen Mobil Listrik Buatan Cina

Rayan Luqman Hakim¹

¹Informatika, Universitas Pembangunan Nasional Veteran Yogyakarta, Indonesia

¹123220100@student.upnyk.ac.id

Informasi Artikel

Received:

Revised:

Accepted:

Published:

Abstract

Purpose: This study aims to analyze public sentiment towards Chinese electric vehicles in Indonesia based on YouTube comments and to evaluate the performance of combined vectorization methods with Machine Learning algorithms.

Design/methodology/approach: The research utilizes YouTube comment data on Aion, BYD, Denza, and Wuling brands. The methodology includes text preprocessing, Synthetic Minority Over-sampling Technique (SMOTE) to handle class imbalance, and feature extraction comparison between TF-IDF and CountVectorizer. Classification is performed using Logistic Regression, Naïve Bayes, and Ensemble Learning (Majority Voting).

Findings/result: Experimental results show that TF-IDF consistently outperforms CountVectorizer, achieving an accuracy of 75.70% on the Aion dataset and 79.89% on Wuling. The Ensemble Learning model combined with TF-IDF proves to be the most robust architecture, effectively minimizing prediction bias compared to single models.

Originality/value/state of the art: This research contributes by implementing a comparative study of vectorization methods integrated with SMOTE and Ensemble Learning specifically for the domain of Chinese electric vehicle sentiment in Indonesia, which is characterized by noisy and unstructured text data.

Keywords: one; two; three

Kata kunci: satu; dua; tiga

Abstrak

Tujuan: Penelitian ini bertujuan untuk menganalisis sentimen publik terhadap mobil listrik buatan Cina di Indonesia berbasis komentar YouTube serta mengevaluasi kinerja kombinasi metode vektorisasi dengan algoritma Machine Learning.

Perancangan/metode/pendekatan: Penelitian menggunakan data komentar YouTube pada merek Aion, BYD, Denza, dan Wuling. Metodologi meliputi pra-pemrosesan teks, penerapan *Synthetic Minority Over-sampling Technique* (SMOTE) untuk menangani ketidakseimbangan kelas, serta komparasi ekstraksi fitur antara TF-IDF dan *CountVectorizer*. Klasifikasi dilakukan menggunakan *Logistic Regression*, *Naïve Bayes*, dan *Ensemble Learning* (*Majority Voting*).

Hasil: Hasil eksperimen menunjukkan bahwa TF-IDF secara konsisten mengungguli *CountVectorizer*, dengan capaian akurasi 75,70% pada dataset Aion dan 79,89% pada Wuling. Model *Ensemble Learning* yang dikombinasikan dengan TF-IDF terbukti menjadi arsitektur paling tangguh (*robust*), efektif meminimalisir bias prediksi dibandingkan model tunggal.

Keaslian/ *state of the art*: Penelitian ini memberikan kontribusi berupa studi komparasi metode vektorisasi yang diintegrasikan dengan SMOTE dan *Ensemble Learning* secara spesifik pada domain sentimen kendaraan listrik Cina di Indonesia yang memiliki karakteristik data teks penuh gangguan (*noisy*).

1. Pendahuluan

Industri otomotif di Indonesia saat ini tengah mengalami transformasi signifikan dengan masuknya gelombang kendaraan listrik (*Electric Vehicle*) buatan produsen asal Cina. Merek-merek seperti Wuling, BYD, dan Aion Hyptec mulai mendominasi pasar dengan menawarkan teknologi canggih dan harga yang kompetitif. Studi oleh Adzhani et al. [1] dan Huzna et al. [2] menyoroti bahwa faktor harga beli dan biaya operasional menjadi determinan utama yang mempengaruhi sentimen masyarakat, di mana konsumen cenderung memprioritaskan aspek ekonomis. Fenomena ini memicu respons beragam dari masyarakat yang banyak dituangkan melalui platform media sosial YouTube. Analisis sentimen terhadap komentar-komentar ini menjadi krusial untuk memetakan persepsi pasar secara akurat.

Tantangan teknis paling mendasar dalam analisis sentimen media sosial adalah ketidakseimbangan distribusi kelas data (*class imbalance*). Sebagai solusi standar, Chawla et al. [3] memperkenalkan teknik SMOTE (*Synthetic Minority Over-sampling Technique*). Efektivitas teknik ini divalidasi oleh Ramadhani & Suryono [4], yang membuktikan bahwa penggabungan SMOTE dengan *Logistic Regression* mampu mendongkrak akurasi hingga 95%. Hal serupa ditemukan oleh Vidasari et al. [5], Karimah et al. [6], dan Yulianto et al. [7], yang secara konsisten menunjukkan bahwa penerapan SMOTE pada dataset ulasan—termasuk pada topik mobil listrik—mampu meningkatkan kemampuan model mengenali kelas minoritas secara lebih objektif, dengan kenaikan akurasi signifikan dari kisaran 50% menjadi di atas 70%.

Dalam ranah algoritma klasifikasi, pemilihan model memerlukan perbandingan karakteristik yang cermat. Penelitian Saraswati et al. [8] memberikan perspektif kritis bahwa meskipun *Naïve Bayes* efisien secara waktu komputasi, algoritma ini cenderung memiliki bias (*False Negative* tinggi) pada dataset tertentu. Sebaliknya, *Logistic Regression* dinilai lebih stabil dan objektif. Ketangguhan *Logistic Regression* ini diperkuat oleh temuan Budianto et al. [9] dan Pratama et al. [10], yang membuktikan bahwa algoritma ini memiliki stabilitas yang lebih baik dibandingkan SVM serta sangat andal menangani data dengan *noise* tinggi seperti media sosial. Meskipun demikian, penulis tetap melibatkan *Naïve Bayes* sebagai *baseline* dengan optimasi *preprocessing stopwords* sebagaimana disarankan Tjen [11].

Upaya untuk menutupi kelemahan model tunggal telah dieksplorasi melalui pendekatan *Ensemble Learning*. Efektivitas metode ini divalidasi oleh Daniati et al. [12] yang membuktikan bahwa penggabungan prediksi menghasilkan keputusan yang lebih *robust*. Secara spesifik, Agustina & Ihsan [13] dan Sherazi et al. [14] merekomendasikan penggunaan teknik *Soft Voting Ensemble*. Berbeda dengan *Hard Voting* yang hanya menghitung suara terbanyak, *Soft Voting* bekerja dengan merata-rata nilai probabilitas keyakinan dari setiap model, sehingga keputusan akhir menjadi lebih presisi.

Selain algoritma, metode ekstraksi fitur (vektorisasi) juga sangat mempengaruhi kinerja model. Studi Zhafira et al. [15], Prasetyo et al. [16], dan Dani et al. [17] secara konsisten menunjukkan bahwa metode TF-IDF sangat relevan dan efektif memberikan bobot pada kata kunci unik. Namun, pendekatan fundamental berbasis frekuensi murni (*CountVectorizer*) tetap memegang peranan krusial sebagai pembanding. Penelitian Suryaningrum [18] menyoroti daya saing *CountVectorizer* yang mampu mencapai akurasi kompetitif (87,14%). Fakta ini mendorong penulis untuk melakukan evaluasi komparatif guna menentukan apakah kompleksitas TF-IDF benar-benar diperlukan ataukah pendekatan sederhana sudah cukup optimal, sebagaimana diteliti pula oleh Mahendra et al. [19] dan Mazta et al. [20] yang menemukan bahwa *CountVectorizer* tetap mampu menghasilkan akurasi tinggi (94,29%) pada kasus klasifikasi teks akademik.


Berdasarkan sintesis literatur di atas, penelitian ini bertujuan mengevaluasi kinerja kombinasi metode vektorisasi (TF-IDF vs *CountVectorizer*) dan algoritma *Machine Learning* (*Ensemble Soft Voting*, LR, NB) dengan penanganan SMOTE untuk analisis sentimen mobil listrik Cina

2. Metode

Penelitian ini menerapkan pendekatan kuantitatif eksperimental untuk membandingkan kinerja metode vektorisasi dan algoritma klasifikasi. Tahapan penelitian dirancang secara sistematis mulai dari pengumpulan data hingga evaluasi model..

2.1. Alur Penelitian

Secara umum, alur penelitian yang dilakukan digambarkan pada Gambar 2.1 Proses dimulai dengan akuisisi data komentar dari YouTube, dilanjutkan dengan pembersihan data (*preprocessing*), penyeimbangan data menggunakan SMOTE, ekstraksi fitur, dan terakhir klasifikasi menggunakan metode *Ensemble Learning*.



Gambar 2. 1 Alur Penelitian

2.2. Pengumpulan Data

Data penelitian diperoleh melalui teknik *scraping* pada kolom komentar video YouTube yang mengulas empat merek mobil listrik Cina, yaitu Aion Hyptec HT, BYD Seal, Denza D9, dan Wuling Air EV. Total data mentah yang berhasil dikumpulkan sebanyak 6.041 komentar. Setelah melalui proses penyaringan manual untuk menghapus komentar *spam* atau tidak relevan, didapatkan total 2.513 data bersih yang telah dilabeli menjadi dua kelas sentimen:

Positif dan Negatif. Distribusi data awal menunjukkan ketidakseimbangan yang signifikan di mana kelas positif cenderung mendominasi.

Tabel 2. 2 Sumber Data

No	Merek	Judul	Channel	Link
1	AION	AION HYPTEC HT INI BIKIN SAYA KHILAF SAMPAI SPK	Fitra Eri	https://youtu.be/S18o2kqYJsc?si=YQPGFyRiiCAhiUrJ
2	AION	HORE! HYPTEC HT PENGGANTI IONIQ 5 BUAT ISTRI SUDAH SAMPAI	Fitra Eri	https://youtu.be/ilqbreKD0GY?si=KCTbTAMtsTEmcRZQ
3	BYD	BYD Seal 2024 Review Indonesia OtoDriver	Otodriver	https://youtu.be/Ui8KJo1rTlc?si=rmhRGDKnmDEUj5OJ
4	BYD	EV YANG KENCANGNYA SEPERTI LAMBORGHINI! : BYD SEAL	Ridwan Hanif	https://youtu.be/nusdFdpL1aA?si=f_5OZAGKr4JOaOK-
5	DENZA	DENZA D9 Katanya Pembunuh Alphard	Motomobi	https://youtu.be/BjxHha8LXf0?si=P_Fl80BculwnlU2O
6	DENZA	BEGINI RASANYA DENZA D9 SI ALPHARD KILLER	Ridwan Hanif	https://youtu.be/Su3zXZ2IHBU?si=VVSxsRc6JYhgIKs
7	WULING	Wuling Air ev 2022 Review Indonesia OtoDriver	Otodriver	https://youtu.be/NzrFOHPHLxc?si=2eC-Ddg_t0HtlvHJ

2.3. Pra Pemrosesan Text

Sebelum masuk ke tahap pemodelan, data teks mentah melalui serangkaian tahapan pra-pemrosesan untuk meningkatkan kualitas fitur yang akan diekstraksi. Tahapan tersebut meliputi:

1. *Case Folding*: Mengubah seluruh huruf menjadi huruf kecil (*lowercase*).
2. *Cleaning*: Menghapus angka, tanda baca, emoji, dan karakter spesial yang tidak memiliki makna sentimen.
3. *Normalization*: Mengubah kata-kata tidak baku (*slang*), singkatan, dan *typo* menjadi bentuk baku sesuai KBBI menggunakan kamus kustom yang telah disusun.
4. *Stopword Removal*: Menghapus kata-kata umum (seperti "yang", "dan", "di") yang sering muncul namun minim informasi.

5. *Negation Handling*: Menangani kata negasi (seperti "tidak", "bukan") dengan cara menggabungkannya dengan kata sifat yang mengikutinya (contoh: "tidak bagus" menjadi "tidak_bagus") agar makna sentimen tidak terbalik.

2.4. Penanganan Ketidakseimbangan Data (SMOTE)

Untuk mengatasi masalah *imbalanced data*, penelitian ini menerapkan metode *Synthetic Minority Over-sampling Technique* (SMOTE). SMOTE bekerja dengan cara membangkitkan sampel sintesis baru untuk kelas minoritas (negatif) berdasarkan *k*-tetangga terdekat (*k-nearest neighbors*) di ruang fitur. Proses ini dilakukan hanya pada data latih (*training set*) untuk menghindari kebocoran data (*data leakage*) ke data uji. Dengan SMOTE, model dapat mempelajari karakteristik kelas minoritas dengan lebih baik tanpa sekadar menduplikasi data yang ada.

2.5. Ekstraksi Fitur dan Klasifikasi

Tahap ini bertujuan mengubah data teks yang telah bersih menjadi representasi numerik agar dapat diproses oleh algoritma *Machine Learning*. Penelitian ini membandingkan dua metode ekstraksi fitur, yaitu *Term Frequency-Inverse Document Frequency* (TF-IDF) dan *CountVectorizer*. TF-IDF digunakan untuk memberikan bobot pada kata berdasarkan tingkat kepentingannya dalam dokumen dan korpus, sedangkan *CountVectorizer* merepresentasikan teks berdasarkan frekuensi kemunculan kata semata (*Bag of Words*).

Fitur yang dihasilkan kemudian digunakan sebagai input untuk tiga skenario model klasifikasi: *Logistic Regression* (LR), *Naïve Bayes* (NB), dan *Ensemble Learning*. *Logistic Regression* dipilih sebagai model *baseline* linear, sementara *Naïve Bayes* (varian *MultinomialNB*) digunakan karena efisiensinya dalam menangani data teks berdimensi tinggi.

Untuk meningkatkan akurasi dan stabilitas prediksi, sistem menerapkan metode *Ensemble Learning* dengan mekanisme *Majority Voting*. Metode ini menggabungkan prediksi dari model LR dan NB, di mana keputusan akhir kelas sentimen ($\hat{y}$) ditentukan berdasarkan suara terbanyak. Secara matematis, mekanisme *Hard Voting* ini dapat dituliskan pada Persamaan (1):

$$\hat{y} = \text{mode}(C_1(x), C_2(x), \dots) \quad (1)$$

Dimana $\hat{y}$ adalah keputusan akhir sentimen hasil *ensemble*, $C_n(x)$ merupakan prediksi kelas yang dihasilkan oleh model dasar ke- n (dalam hal ini *Logistic Regression* dan *Naïve Bayes*), dan fungsi *mode* mengambil nilai yang paling sering muncul (mayoritas) sebagai prediksi final.

3. Hasil dan Pembahasan

Bagian ini memaparkan hasil eksperimen yang dilakukan terhadap dataset komentar mobil listrik Cina. Evaluasi difokuskan pada dua aspek utama: perbandingan efektivitas metode vektorisasi (TF-IDF vs *CountVectorizer*) dan kinerja algoritma klasifikasi dalam menangani data tidak seimbang yang telah diproses menggunakan SMOTE.

3.1. Analisis Perbandingan Metode Vektorisasi

Evaluasi metode vektorisasi bertujuan untuk mengetahui seberapa efektif representasi teks menggunakan pembobotan (*TF-IDF*) dibandingkan dengan frekuensi kata sederhana (*CountVectorizer*) dalam menangani karakteristik komentar pada empat dataset mobil listrik yang berbeda.

Tabel 3. 1 Hasil Pengujian pada Dataset Aion Hyptec HT

No	Model	Akurasi	Presisi	Recall	F1-Score
1.	Ensemble + TF-IDF	75.70%	0.75	0.76	0.75
2.	Logistic Regression + TF-IDF	74.77%	0.74	0.75	0.74
3.	Naïve Bayes + TF-IDF	73.83%	0.76	0.74	0.75
4.	Naïve Bayes + CountVectorizer	73.83%	0.74	0.74	0.74
5.	Ensemble + CountVectorizer	65.42%	0.72	0.65	0.67
6.	Logistic Regression + CountVectorizer	63.55%	0.67	0.64	0.65

Berdasarkan Tabel 3.1, pengujian pada dataset Aion Hyptec HT menunjukkan dominasi metode TF-IDF. Model *Ensemble Learning* yang dikombinasikan dengan TF-IDF berhasil meraih performa tertinggi dengan akurasi 75,70%. Sebaliknya, penggunaan *CountVectorizer* pada model yang sama justru mengalami penurunan performa yang signifikan menjadi 65,42%. Hal ini mengindikasikan bahwa pada dataset Aion, fitur pembobotan sangat krusial untuk memisahkan kata-kata bermakna dari *noise*.

Tabel 3. 2 Hasil Pengujian pada Dataset BYD Seal

No	Model	Akurasi	Presisi	Recall	F1-Score
1.	Ensemble + TF-IDF	75.45%	0.75	0.75	0.75
2.	Logistic Regression + TF-IDF	72.73%	0.74	0.73	0.73
3.	Naïve Bayes + CountVectorizer	69.09%	0.72	0.69	0.70
4.	Naïve Bayes + TF-IDF	67.27%	0.72	0.67	0.68
5.	Ensemble + CountVectorizer	65.45%	0.66	0.65	0.66
6.	Logistic Regression + CountVectorizer	62.73%	0.72	0.63	0.64

Pola serupa terlihat pada Tabel 3.2 untuk dataset BYD Seal. Kombinasi *Ensemble* dengan TF-IDF kembali menjadi yang paling unggul dengan akurasi 75,45%, diikuti oleh *Logistic Regression* dengan TF-IDF (72,73%). Metode *CountVectorizer* cenderung menghasilkan akurasi di bawah 70% pada mayoritas model. Konsistensi ini menegaskan bahwa TF-IDF lebih mampu menangani variasi kata pada komentar yang membahas merek Aion dan BYD.

Tabel 3. 3 Hasil Pengujian pada Dataset Denza D9

No	Model	Akurasi	Presisi	Recall	F1-Score
1.	Naïve Bayes + CountVectorizer	75.42%	0.75	0.75	0.75
2.	Naïve Bayes + TF-IDF	74.58%	0.76	0.75	0.75

3.	Ensemble + TF-IDF	73.73%	0.74	0.74	0.74
4.	Logistic Regression + TF-IDF	72.03%	0.72	0.72	0.72
5.	Logistic Regression + CountVectorizer	69.49%	0.72	0.69	0.70
6.	Ensemble + CountVectorizer	68.64%	0.74	0.69	0.70

Namun, fenomena menarik terjadi pada Tabel 3.3 (Dataset Denza D9). Berbeda dengan dua dataset sebelumnya, metode *CountVectorizer* justru tampil kompetitif. Model *Naïve Bayes* dengan *CountVectorizer* mencatatkan akurasi tertinggi sebesar 75,42%, mengungguli metode TF-IDF meskipun dengan selisih yang tipis. Hal ini menunjukkan bahwa dataset Denza kemungkinan memiliki struktur kalimat yang lebih sederhana atau kosa kata yang lebih homogen, sehingga pendekatan frekuensi kata sederhana sudah cukup efektif.

Tabel 3. 4 Hasil Pengujian Model pada Dataset Wuling Air Ev


No	Model	Akurasi	Presisi	Recall	F1-Score
1.	Logistic Regression + TF-IDF	79.89%	0.80	0.80	0.80
2.	Naïve Bayes + TF-IDF	78.74%	0.79	0.79	0.79
3.	Logistic Regression + CountVectorizer	77.01%	0.78	0.77	0.77
4.	Naïve Bayes + CountVectorizer	74.71%	0.76	0.75	0.75
5.	Ensemble + CountVectorizer	71.84%	0.73	0.72	0.72
6.	Ensemble + TF-IDF	70.69%	0.70	0.71	0.70

Sementara itu, pada Tabel 3.4 (Dataset Wuling Air EV), algoritma tunggal *Logistic Regression* dengan fitur TF-IDF terbukti menjadi arsitektur paling optimal dengan akurasi mencapai 79,89%. Pada kasus ini, model *Ensemble* justru mengalami penurunan kinerja dibandingkan model tunggalnya. Meski demikian, jika dilihat dari sisi vektorisasi, TF-IDF tetap mendominasi posisi teratas dibandingkan *CountVectorizer*.

3.2. Evaluasi Kinerja Algoritma Klasifikasi dan Dampak SMOTE

Selain akurasi, keberhasilan model dalam menangani ketidakseimbangan data dievaluasi menggunakan *Confusion Matrix*. Tanpa penanganan yang tepat, model pada data *imbalanced* cenderung memprediksi semua data sebagai kelas mayoritas (Positif) untuk mendapatkan akurasi semu yang tinggi, namun gagal mengenali kelas minoritas (Negatif).

Penerapan metode SMOTE pada penelitian ini terbukti efektif mengatasi masalah tersebut. Hal ini tergambar pada visualisasi hasil prediksi model terbaik (*Ensemble Learning*) pada dataset Wuling Air EV yang ditunjukkan oleh Gambar 3.1



Gambar 3. 1 Confusion Matrix Wuling Air Ev

4. Kesimpulan dan Saran

Berdasarkan hasil penelitian dan pembahasan, dapat disimpulkan bahwa kombinasi metode *Ensemble Learning* dengan ekstraksi fitur TF-IDF merupakan arsitektur terbaik untuk analisis sentimen mobil listrik Cina, dengan capaian akurasi tertinggi mencapai 79,89% pada dataset Wuling Air EV. Metode TF-IDF terbukti lebih efektif dalam menangani karakteristik teks komentar YouTube yang tidak terstruktur dibandingkan *CountVectorizer*. Selain itu, penerapan teknik SMOTE memegang peranan krusial dalam mengatasi ketidakseimbangan data, sehingga model tidak mengalami bias terhadap kelas mayoritas.

Penelitian ini masih memiliki keterbatasan pada penanganan bahasa gaul dan sarkasme yang kompleks. Untuk pengembangan selanjutnya, disarankan menerapkan metode *Deep Learning* seperti LSTM atau BERT yang memiliki kemampuan lebih baik dalam menangkap konteks semantik kalimat. Perluasan sumber data ke platform lain seperti Twitter (X) atau Instagram juga disarankan untuk mendapatkan variasi gaya bahasa yang lebih beragam.

Daftar Pustaka

- [1] A. Adzhani, A. P. Giovani, dan A. P. Wibawa, "Analisis Preferensi Konsumen Kendaraan Listrik Menggunakan Pendekatan Mixed Methods," *Jurnal Transportasi Multimoda*, vol. 21, no. 1, 2025.
- [2] A. N. Huzna, I. Nurhayati, A. E. Saputri, dan M. Q. Huda, "Analisis Sentimen Terhadap Mobil Listrik Di Indonesia Pada Twitter: Penerapan Naïve Bayes Classifier," *Just IT: Jurnal Sistem Informasi, Teknologi Informasi dan Komputer*, vol. 14, no. 2, pp. 80-149, 2024.

- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, dan W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [4] B. Ramadhani dan R. R. Suryono, "Komparasi Algoritma Naïve Bayes dan Logistic Regression Untuk Analisis Sentimen Metaverse," *Jurnal Media Informatika Budidarma*, vol. 8, no. 2, pp. 714-725, 2024.
- [5] V. H. Vidasari, H. Hairani, H. Santoso, dan F. M. Amin, "Penerapan Logistic Regression dan SMOTE untuk Memprediksi Atrisi Karyawan pada Imbalanced Data," *SEMINAR NASIONAL CORISINDO*, pp. 7-14, 2025.
- [6] A. Karimah, G. Dwilestari, dan M. Mulyawan, "Analisis Sentimen Komentar Video Mobil Listrik di Platform Youtube dengan Metode Naive Bayes," *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 8, no. 1, pp. 45-50, 2024.
- [7] M. F. Yulianto, F. M. Hana, dan A. Prihandono, "Analisis Sentimen Masyarakat Terhadap Mobil Listrik Di Youtube Dengan Metode Naive Bayes Dan SMOTE," *Jurnal Ilmiah Informatika Global*, vol. 15, no. 1, 2025.
- [8] D. Y. Saraswati, M. R. Handayani, K. Umam, dan M. I. Mustofa, "Sentiment Classification Comparison Using Naïve Bayes and Logistic Regression," *Jurnal Media Informatika Budidarma*, vol. 9, no. 4, 2025.
- [9] A. G. Budianto, R. Rusilawati, A. T. E. Suryo, G. R. Cahyono, dan A. F. Zulkarnain, "Perbandingan Performa Algoritma Support Vector Machine (SVM) dan Logistic Regression untuk Analisis Sentimen Pengguna Aplikasi Retail di Android," *Jurnal Sains dan Informatika*, vol. 10, no. 2, 2024.
- [10] Y. Pratama, D. T. Murdiansyah, dan K. M. Lhaksmana, "Analisis Sentimen Kendaraan Listrik Pada Media Sosial Twitter Menggunakan Algoritma Logistic Regression dan Principal Component Analysis," *Jurnal Media Informatika Budidarma*, vol. 7, no. 1, pp. 529-535, 2023.
- [11] J. Tjen, "Pengaruh Jenis Stopwords terhadap Akurasi Model Multinomial Naïve Bayes dalam Proses Sentimen Analisis," *Jurnal Ilmu Komputer dan Sistem Informasi*, vol. 13, no. 1, pp. 13–22, 2025.
- [12] E. Daniati, et al., "Analisis Sentimen dengan Pendekatan Ensemble Learning dan Word Embedding pada Twitter," *Jurnal Teknik Informatika*, vol. 4, no. 2, 2023.
- [13] N. Agustina dan C. N. Ihsan, "Pendekatan Ensemble untuk Analisis Sentimen Covid19 Menggunakan Pengklasifikasi Soft Voting," *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK)*, vol. 10, no. 2, pp. 263-270, 2023.
- [14] S. W. A. Sherazi, J. W. Bae, dan J. Y. Lee, "A soft voting ensemble classifier for early prediction and diagnosis of occurrences of major adverse cardiovascular events for STEMI and NSTEMI during 2-year follow-up in patients with acute coronary syndrome," *PLoS ONE*, vol. 16, no. 6, p. e0249338, 2021.
- [15] Z. A. Zhafira, Y. Sibaroni, dan S. Satyahadewi, "Analisis Sentimen Hotel Menggunakan Naïve Bayes Classifier dengan Pembobotan TF-IDF," *e-Proceeding of Engineering*, vol. 8, no. 5, pp. 9845-9852, 2021.

-
- [16] T. Prasetyo, A. A. Waskita, dan T. Taryo, "Analisis Sentimen Pengguna Seputar Kendaraan Listrik Di Twitter Dengan Penerapan Algoritma Naïve Bayes, KNN, dan Decision Tree," *Jurnal Informatika dan Teknik Elektro*, 2025.
- [17] A. R. Dani, et al., "Komparasi Kinerja SVM Menggunakan Ekstraksi Fitur Word2Vec dan TF-IDF," *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, vol. 8, no. 1, 2024.
- [18] K. M. Suryaningrum, "Comparison of the TF-IDF Method with the Count Vectorizer to Classify Hate Speech," *Jurnal EMACS (Engineering, Mathematics and Computer Science)*, vol. 5, no. 2, pp. 79-83, 2023.
- [19] D. Mahendra, et al., "Analisis Sentimen Ulasan Aplikasi Menggunakan Metode KNN dengan Komparasi Ekstraksi Fitur TF-IDF dan CountVectorizer," *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, vol. 7, no. 3, 2023.
- [20] M. A. Mazta, E. Saputra, dan M. R. A, "Perbandingan Kinerja TF-IDF dan Count Vectorization Pada Sistem Rekomendasi Judul Skripsi Berbasis Content-Based Filtering," *Jurnal Informatika Teknologi dan Sains (JINTEKS)*, vol. 7, no. 4, pp. 1807-1816, 2025.
- .